

LMFT Workbench — AI大模型训练工程师 全链路微调工作台

作者：刘林阳 | 15+年企业级软件研发+AI工程落地经验


项目状态：v1.6.2 | 核心链路验收通过（场景1→2→3→4→5）

一、一句话说清楚它是什么

LMFT Workbench 是一个"看得见、能点开、能迭代"的 AI 全链路微调工程平台。

它把大模型微调的完整流程——从种子设计、数据增强、LoRA 训练、对比评估、蒸馏量化到 RAG 融合——做成了一个**可交互的三栏可视化工作台**。打开浏览器就能操作，不需要写一行代码。

可以帮助**内部转岗工程师**快速理解掌握该领域的概念、知识、工作流程、实操技巧，可真实运行。



二、五大场景全景

整个系统覆盖 AI 大模型微调全链路的 **5 个核心场景**，每个场景都是一个完整的 IPO（Input-Process-Output）模块化设计：

localhost:8000

Summarize🔍🌟🔄👤

F-Focus(最近)P-Projects(项目)A-Areas(领域)R-Resources(资源)O-Output(输出)AR-Archives(归档)T-Tools(工具平台)N-Notes(笔记)B-Books(书籍)

LMFT WorkbenchAI大模型训练工程师·全链路微调工作台

航空客服(退改签/投诉/行李/延误/特殊服务)▶运行全部📄导出报告包

54种子172训练集2.1MBLoRA适配器5场景数

全链路 workflow 点击任一节点查看详情

数据工程❏就绪

→

LoRA微调✅已运行

→

评估对比❏就绪

→

蒸馏量化❏就绪

→

RAG融合❏就绪

JD职责 ↔ 场景覆盖矩阵 面试官看这里: 你要的, 我都有

JD职责	数据工程	LoRA微调	评估对比	蒸馏量化	RAG融合
① 数据工程	✅	—	—	—	—
② 垂类模型微调	—	✅	✅	—	—
③ 指令对齐与评估	—	—	✅	—	—
④ 蒸馏与轻量化	—	—	—	✅	—
⑤ 知识融合	—	—	—	—	✅

✅已跑通🔧需GPU/架构设计👉不直接对应

点击行展开JD原文

场景详情 点击进入操作

数据工程

构建航空客服指令数据集: 种子 → 增强 → 清洗 → 训练/测试拆分

❏就绪 进入 →

LoRA微调

Qwen2.5-0.5B + LoRA 垂类微调, 支持按阶段保存版本化适配器

✅已训练 进入 →

评估对比

迭代对比核心: 选两个阶段模型, 同一组测试题并推理, 打分+差异

❏就绪 进入 →

蒸馏量化

Teacher→Student蒸馏 + INT8量化, 三轴对比

❏就绪 进入 →

RAG融合

RAG / 微调 / 融合 三方案对比


❏就绪 进入 →

📡 场景1：数据工程（✅ 已完成）

构建航空客服指令数据集的全流程：种子设计 → 增强 → 清洗 → 训练/测试拆分

IPO	内容
I（输入）	种子问答对（目前50条，覆盖退改签/投诉/行李/延误/特殊服务 5大主题...
P（处理...）	DeepSeek API 逐条变体生成 + 规则兜底增强
O（输出...）	增强后训练集 + 测试集 + 统计数据报告

- 50 条种子 → 172 条训练数据 + 11 条测试数据
- 在线预览 & 下载 JSON




🎯 场景2：LoRA 微调（✅ 已完成）

基于 Qwen2.5 的 LoRA/QLoRA 高效微调，按阶段保存版本化适配器

IPO	内容
I（输入）	训练数据 + LoRA 配置参数（r/alpha/dropout/epochs/lr...）
P（处理）	CPU 全流程训练，异步轮询进度，20+分钟长任务不阻塞
O（输出）	版本化适配器 + Loss 曲线 + 训练报告

- **双模式设计**：查看历史阶段（面板联动切换）vs 调入最新数据开启新训练
- **阶段版本快照**：每次训练的种子、数据、适配器、Loss 曲线全部存档
- **已验证**：172 条数据 × 8 epoch ≈ 40 分钟训练，Loss 从 5.99 降至 3.81



场景3：评估对比（✅ 已完成）

迭代闭环的核心——两个阶段在同一组测试题上并排推理、打分、差异分析

IPO	内容
I（输入）	选定阶段 A（基线）和阶段 B（新版）
P（处理）	两阶段模型分别推理测试题 → ROUGE-L/BLEU 评分 → 逐题对比
O（输出）	评分看板 + 对比图表 + 逐题对比 + 完整下载报告

- 异步后台评估（10~20分钟），前端实时轮询进度
- 4 张评分卡 + 3 张 Plotly 图表 + 逐题展开对比
- 支持快速迭代判断："这次微调有效果吗？" → 量化结论

localhost:8000/scene/3

F-Focus(最近)P-Projects(项目)A-Areas(领域)R-Resources(资源)O-Output(输出)AR-Archives(归档)T-Tools(工具平台)N-Notes(笔记)B-Books(书籍)

首页评估对比指令对齐就绪

数据工程LoRA微调评估对比蒸馏量化RAG融合

① 数据工程② LoRA微调③ 评估对比④ 蒸馏量化⑤ RAG融合

① 输入 选择对比阶段

阶段 A

阶段 1「基础客服概念簇」Loss:5.99

阶段 B

阶段 4「阶段4」Loss:3.80946044921875

阶段对比

阶段 1

种子 20 条

Loss 5.99

LoRA

概念 退改签、行李运输、航班延误

VS

阶段 4

种子 54 条

Loss 3.80946044921875

LoRA

概念 延误与航班中断、投诉与赔偿、特殊服务

就绪, 可以开始评估

测试集

题数 11

11 测试题数

data/test/test.json

② 处理 评估对比 已完成

开始评估

SkillPython评估日志

评估对比中心

Skill — 评估对比中心

一、概念、目的与作用

评估对比中心是微调工作台的迭代闭环核心节点。它的作用是：
1. 判断微调效果：加载两个阶段的 LoRA 适配器，在同一组测试题上做并排推理，用客观指标（ROUGE-L、BLEU）度量哪个阶段表现更好
2. 驱动迭代决策：评估结果直接回答“补充了某个概念簇的种子后，模型有没有变好”——变好了就继续，没有就回溯
3. 暴露模型弱点：逐题对比可以精确定位模型在哪类问题上表现差（退改签 OK、投诉不行），从而指导下一轮数据补充方向

场景3在工作台中的位置

③ 产出 评估结果

评分总览对比图表逐题对比

0.1610

阶段1（基础客服概念簇） ROUGE-L

0.1714

阶段4（阶段4） ROUGE-L

0.29

阶段1（基础客服概念簇） BLEU

0.26

阶段4（阶段4） BLEU

+6.46%

变化率

阶段4（阶段4）

胜出方

阶段4（阶段4）在 ROUGE-L 上提升了 6.46%（相比阶段1（基础客服概念簇））

下载报告新建阶段

11 测试题数

4 阶段数

3 有 LORA

0.2438

最佳 ROUGE-L

当前最高分

评估历史

暂无

场景4：蒸馏量化（迭代升级中）

Teacher → Student 知识蒸馏 + INT8 量化，满足私有化部署需求

IPO	内容
I（输入）	已微调的 Teacher 模型 + Student 模型选择
P（处理）	知识蒸馏 + INT8 量化 + 三轴对比（精度/速度/体积）
O（输出）	蒸馏量化报告 + 三轴对比图 + 量化后模型

IPO 交互模块已设计就绪，正在迭代升级中。

首页蒸馏量化指令对齐就绪

数据工程LoRA微调评估对比蒸馏量化RAG融合

大模型压缩为1/4大小，保留80%+效果

待运行

数据预览

该场景暂无预览数据

操作

运行此场景配置原理

BI 面板

状态

未运行

指标


运行历史

还没有运行记录

场景5：RAG 融合（迭代升级中）

IPO	内容
I（输入）	知识库（业务文档 + 工作手册）+ 微调适配器
P（处理）	三种方案并行推理 + 效果评分对比
O（输出）	三联对比报告 + 方案推荐 + 溯源码

IPO 交互模块已设计就绪，正在迭代升级中。



三、核心能力展示

🔥 能力 1：全链路工程落地

不是单个 Notebook，不是拼凑的教程代码。5 个场景覆盖了从"原始种子"到"可评估的微调模型"的全链路，每个场景都是一个独立可运行的 IPO 模块。数据流可以在场景之间完整串联：场景1产出 → 场景2训练 → 场景3评估。

🔥 能力 2：迭代思维与工程规范

系统内置了一套完整的**阶段版本快照**体系：

```
versions/  
  stage_1/  - 基础客服概念簇（20种子，Loss=5.99）  
  stage_2/  - 种子优化+参数调优（20种子，Loss=3.67）  
  stage_3/  - [跳过]  
  stage_4/  - 50种子扩增（54种子，Loss=3.81）
```

每一个阶段都是一次完整的快照——用了哪份种子、Train/Test 数据是什么、Loss 曲线、LoRA 权重、训练超参数——全部存档。选中任意阶段，面板联动展示该阶段的完整状态。这

是可以"迭代一百次"的生产环境。

配套工程规范包括：Git 双 remote 版本管理、编码/弹窗/布局规约、Multi-Agent 协作工程规范。项目本身就是这套规范的第一验证案例。

 能力 3：技术深度——微调 vs RAG 的路线判断

全链路跑通后，项目产出了一个硬核认知——这不是理论推演，是经过三轮实际训练验证的：

结论	证据
纯微调不能单独用于知识密集型问答	Qwen2.5-0.5B × 172 条训练数据，ROUGE-L 最高仅 0.17，BLEU 最高 0.37，超出训练分布后必然胡言乱语
微调的正确定位是"风格对齐"	调整语气、回复格式、思考方式，不是注入专业知识
知识注入靠 RAG	检索引擎从完整知识库（工作手册/政策文档/FAQ）中拉相关片段，LLM 做阅读理解——工业级可靠的架构

能说出"这个方案行不通、为什么行不通、正确的路应该怎么走"——这是 20 年工程经验沉淀出来的判断力。

 能力 4：技术栈宽度

领域	技术选型	深度
基础模型	Qwen2.5-0.5B（可升 1.5B/7B）	从头调通全链路
微调方案	LoRA（r=8，α=16，q_proj+v_proj）	参数调优、版本化管理
数据工程	种子增强 + DeepSeek API 生成 + 多倍扩增	50 种子 → 172 条训练
评估体系	ROUGE-L + BLEU + 逐题对比 + 人工质检	3 层检验
混合架构	微调+知识库+RAG	深度认知独立判断
后端	FastAPI + TaskManager 异步	模块化重构
前端	Jinja2 + Plotly + IPO 三栏布局	可交互可迭代
工程	Git 双 remote + 版本化 + Skill/规约体系	企业级规范
多 Agent 协作	OpenClaw sub-agent + CLAUDE.md + AGENTS.md	多平台兼容

四、项目架构与 workflow

整体架构（FastAPI 模块化）

server.py

app_config.py

routes/pages.py

routes/scenes.py

services/task_manager.py

← 应用入口 (~50行, 只负责注册)

← 场景/JD/统计函数 (~175行)

← 页面路由

← 全部场景 API (~542行)

← 异步任务管理 (~100行)

交互体验

每个场景采用 IPO 三栏布局 (Input → Process → Output):

- **Input (输入区)**: 调参数、选数据、设配置
- **Process (处理区)**: 实时日志、进度条、Loss 曲线
- **Output (输出区)**: 评分卡、图表、下载报告

从数据到训练到评估，浏览器里一站式完成。

五、开放的合作方向

方向	适合场景	切入点
企业 AI 能力搭建	企业内部搭建微调 + RAG 知识库	全链路搭建能力 + 工程规范
AI 教育/培训	可视化教学"微调原理"	IPO 架构天然适合教学
企业知识库+AI Agent	客服、文档、SOP 智能化	微调+RAG 的深度对比经验
一人公司/AI 产品	快速验证 AI 可行性	从数据到评估的闭环工具

六、定位与边界

这个系统是

-  一个全链路微调的**工程验证平台**
-  一个展示全链路工程能力的**技术展品**
-  一个可以引入企业数据、快速跑验证的**可行性测试床**

这个系统不是

-  不是一个可以直接商用的产品 (缺用户系统、权限管理、前端封装)
-  不是学术论文级别的实验平台 (没有穷尽超参搜索、多轮 ablation)
-  不是一个"训完就能部署上线"的完整方案 (量化部署、服务化、运维是后续工作)

坦诚是专业的底气——知道项目在什么阶段、缺什么、下一步怎么走。

七、关于我

- **15+年企业级软件经验**：从 Java 代码写到产品线、写到部门经理，做过 MRO/ERP/SOP/BI 驾驶舱——知道什么叫"能上线的系统"
 - **跨领域技术判断力**：MRO 时代航空维修 ERP 的系统可靠性标准，平移到了 AI 时代的评估体系设计
 - **实战验证的结论**：项目的核心洞见（微调不是知识注入、RAG 才是正路）是用三轮训练、十个小时的 CPU 烤出来的
 - **能说清楚"什么能做、什么不能做"**：在 AI 泡沫期，给出诚实技术判断的能力比写代码的能力更稀缺
-

联系

- 刘林阳
- 邮箱： liulinyang85@yeah.net
- 电话： 18976426325
- 项目代码（部分公开）： <https://github.com/wind-laughing/lmft-demo>